



UNIVERSIDADE DO OESTE DE SANTA CATARINA
ÁREA DE CIÊNCIAS EXATAS E TECNOLÓGICAS
Engenharia da Computação

GLOSSÁRIO TÉCNICO

CAPÍTULO 1: BUILD A LARGE LANGUAGE MODEL (FROM SCRATCH)

Acadêmicos: Arthur de Marco e Lucas Zamonier

Professor: Kleyton Hoffmann

Componente curricular: Inteligência Artificial e Sistemas Inteligentes

Glossário Técnico – Capítulo 1

Build a Large Language Model (From Scratch)

BERT: Modelo baseado no submódulo codificador (encoder) do Transformer, treinado para prever palavras ocultas em uma frase, sendo amplamente utilizado em tarefas de classificação de texto.

Comportamento Emergente (Emergent behavior): Capacidades surpreendentes que o modelo passa a demonstrar, como realizar traduções de idiomas, resultantes da exposição a grandes volumes de dados diversos durante o treinamento para prever a próxima palavra, e não por treinamento explícito na tarefa.

Deep Learning (Aprendizado Profundo): Subcampo do aprendizado de máquina que utiliza redes neurais artificiais com múltiplas camadas (três ou mais) para modelar padrões complexos e extrair características automaticamente.

Encoder e Decoder (Codificador e Decodificador): Submódulos da arquitetura Transformer original. O codificador processa e codifica o texto de entrada em vetores, enquanto o decodificador utiliza essas representações para gerar o texto de saída, passo a passo.

Few-shot learning: Habilidade de um modelo de linguagem de aprender a executar uma nova tarefa recebendo apenas um número muito pequeno de exemplos específicos fornecidos na entrada.

Finetuning (Ajuste Fino): Segunda etapa do treinamento, onde um modelo fundacional previamente treinado é especializado utilizando um conjunto de dados menor e rotulado para realizar tarefas específicas, como classificar textos ou seguir instruções de usuários.

Generative AI (GenAI - IA Generativa): Categoria abrangente de inteligência artificial focada na criação de novas mídias e conteúdos. Os LLMs se enquadram nessa categoria devido à sua capacidade de gerar textos originais.

GPT (Generative Pretrained Transformer): Modelo baseado quase exclusivamente no submódulo decodificador (decoder) do Transformer, desenhado para processamento unidirecional (da esquerda para a direita) focado em prever a próxima palavra, sendo ideal para tarefas de geração de texto.

Large Language Models (LLMs): Redes neurais profundas, frequentemente com dezenas ou centenas de bilhões de parâmetros, projetadas para processar, gerar e compreender a linguagem humana de forma coerente, após intenso treinamento com enormes conjuntos de dados textuais.

Machine Learning (Aprendizado de Máquina): Área da inteligência artificial focada no desenvolvimento de algoritmos capazes de aprender padrões e tomar decisões ou previsões a partir de dados, sem a necessidade de serem explicitamente programados com regras manuais.

Mecanismo de Autoatenção (Self-Attention): Mecanismo essencial da arquitetura

Transformer que permite ao modelo ponderar seletivamente a importância de diferentes partes da sequência de entrada (tokens) ao mesmo tempo, capturando contextos e relacionamentos de longa distância.

Pretraining (Pré-treinamento): Primeira e extensa fase de treinamento de um LLM com vastos volumes de texto bruto não rotulado. Nesta fase, o modelo utiliza aprendizagem autossupervisionada para prever a próxima palavra, adquirindo um amplo entendimento da linguagem e gerando um modelo fundacional.

Transformer: Arquitetura avançada de rede neural baseada em mecanismos de atenção, introduzida originalmente para tarefas de tradução de máquina. Ela serve como espinha dorsal para a vasta maioria dos LLMs modernos por sua eficácia no processamento de linguagem.

Zero-shot learning: Capacidade do modelo de generalizar o que aprendeu para executar uma tarefa completamente nova de forma correta sem a apresentação de qualquer exemplo prévio na sua entrada de texto.